

COMPARISON OF EXTRA TREES REGRESSION AND CART IN MODELLING E-COMMERCE PRODUCT SHIPPING COSTS IN INDONESIA

PERBANDINGAN EXTRA TREES REGRESSION DAN CART DALAM PEMODELAN BIAYA PENGIRIMAN PRODUK E-COMMERCE DI INDONESIA

Dewa Rizky Meidiva Pratama¹, Bilal Muhammad Thalib¹, Arantxa Aulia¹, Sofia Lorena¹, and Septian Rahardiantoro¹

¹Department of Statistics, IPB University, Indonesia

[‡]corresponding author: billythalib@apps.ipb.ac.id

Copyright © 2026 Dewa Rizky Meidiva Pratama, Bilal Muhammad Thalib, Arantxa Aulia, Sofia Lorena, and Septian Rahardiantoro. This is an open-access article distributed under the Creative Commons Attribution License, which permits unrestricted use, distribution, and reproduction in any medium, provided the original work is properly cited.

Abstract

This study aims to compare the performance of two tree-based machine learning methods in modeling e-commerce shipping costs in Indonesia, namely Extra Trees Regression and Classification and Regression Tree (CART). The dataset used consisted of 20,848 sales transaction observations obtained from an e-commerce business, of which 19,033 observations were retained for analysis after the preprocessing stage. Predictor variables included total product weight, quantity, destination province, shipping option, product category, payment method, as well as engineered features such as the weight-to-quantity ratio and logarithmic transformation of product weight. Model evaluation was conducted using RMSE and MAPE metrics on a 20% test dataset. The results indicate that CART demonstrated better predictive performance than Extra Trees Regression, achieving an RMSE of 5,159.55 and a MAPE of 36.06%, compared with an RMSE of 5,221.36 and a MAPE of 37.97% for Extra Trees Regression. Feature importance analysis revealed that destination province and weight-related variables were the most influential predictors of shipping costs. These findings suggest that tree-based methods have strong potential for modeling the nonlinear characteristics of e-commerce shipping costs.

Keywords: e-commerce logistics, shipping cost prediction, Extra Trees regression, CART regression, machine learning

Abstrak

Penelitian ini bertujuan untuk membandingkan performa dua metode *machine learning* berbasis pohon keputusan dalam memodelkan biaya pengiriman e-commerce di Indonesia, yaitu Extra Trees Regression dan Classification and Regression Tree (CART). Dataset yang digunakan terdiri atas 20.848 observasi transaksi penjualan yang diperoleh dari bisnis e-commerce dan setelah proses preprocessing, sebanyak 19.033 observasi digunakan dalam analisis. Variabel prediktor meliputi total berat produk, kuantitas, provinsi tujuan, opsi pengiriman, kategori produk, metode

pembayaran, serta fitur hasil rekayasa seperti rasio berat per kuantitas dan transformasi logaritma berat. Evaluasi model dilakukan menggunakan metrik RMSE dan MAPE pada data uji sebesar 20%. Hasil penelitian menunjukkan bahwa CART menunjukkan performa prediktif yang lebih baik dibandingkan Extra Trees Regression dengan menghasilkan RMSE sebesar 5.159,55 dan MAPE sebesar 36,06%, dibandingkan dengan RMSE sebesar 5.221,36 dan MAPE sebesar 37,97% pada Extra Trees Regression. Analisis *feature importance* menunjukkan bahwa provinsi tujuan dan variabel terkait berat produk merupakan prediktor paling berpengaruh terhadap biaya pengiriman. Temuan ini menunjukkan bahwa metode berbasis pohon keputusan memiliki potensi yang baik dalam memodelkan karakteristik nonlinier pada biaya pengiriman e-commerce.

Kata Kunci: logistik e-commerce, prediksi biaya pengiriman, regresi extra trees, regresi cart, machine learning

1. Pendahuluan

Perkembangan teknologi digital telah mendorong transformasi signifikan dalam sektor perdagangan global, termasuk di Indonesia. Laporan e-Conomy SEA dari Google, Temasek Holdings, dan Bain & Company mencatat Indonesia sebagai pasar e-commerce utama di Asia Tenggara dengan transaksi yang terus tumbuh, sehingga meningkatkan kompleksitas sistem logistik dan distribusi barang. Dalam konteks ini, biaya pengiriman dapat memengaruhi keputusan pembelian konsumen (Bansal & Muzatko, 2021). Struktur biaya pengiriman dipengaruhi oleh berbagai faktor operasional seperti berat barang, kuantitas pesanan, lokasi tujuan, serta metode pengiriman, di mana berat kiriman dan jarak distribusi merupakan determinan utama dalam pembentukan tarif logistik (Harani et al., 2025).

Pemodelan biaya pengiriman sering kali dihadapkan pada kompleksitas struktural mengingat data logistik umumnya bersifat heterogen, tidak berdistribusi normal, serta kerap mengandung *outliers* yang dapat memengaruhi stabilitas estimasi model (Zhao, 2024; Cebeci et al., 2025). Fenomena ini mengindikasikan bahwa keterkaitan antara variabel operasional dan biaya logistik cenderung bersifat nonlinier. Oleh karena itu, pendekatan *machine learning* berbasis pohon (*tree-based models*) menjadi alternatif yang signifikan karena kemampuannya dalam menangkap hubungan nonlinier tanpa bergantung pada asumsi parametrik yang ketat (Chowdhury et al., 2021).

Salah satu pendekatan *ensemble tree-based* yang diimplementasikan adalah *Extremely Randomized Trees* (Extra Trees) sebagaimana dipelopori oleh Geurts et al. (2006). Algoritma ini mengonstruksi sekumpulan pohon keputusan dengan memperkenalkan tingkat randomisasi yang tinggi pada seleksi atribut dan penentuan titik pemisahan guna mengoptimalkan kemampuan generalisasi serta mereduksi varians estimasi model. Implementasi metode ini terbukti efektif dalam memodelkan interaksi variabel yang kompleks pada data dengan karakteristik non-sederhana (Hameed et al., 2021). Sebagai instrumen pembanding, digunakan metode *Classification and Regression Tree* (CART) yang diperkenalkan oleh Breiman et al. (1984), yang merupakan pendekatan pohon keputusan tunggal dengan tingkat

interpretabilitas tinggi dan kerap diposisikan sebagai *baseline model* dalam berbagai studi *machine learning* (Lewis, 2000).

Beberapa penelitian sebelumnya telah mengkaji prediksi biaya logistik menggunakan pendekatan machine learning. Jang (2023) menggunakannya untuk memprediksi biaya pengiriman pada platform freight brokerage, Arfeen (2024) memodelkan biaya transportasi dengan mempertimbangkan variabel operasional pengiriman, sementara Harani et al. (2025) menunjukkan bahwa model ensemble tree-based memberikan hasil prediksi yang lebih baik dibandingkan regresi linier. Meskipun demikian, penelitian yang secara khusus membandingkan Extra Trees Regression dan CART untuk memodelkan biaya pengiriman pada data transaksi e-commerce di Indonesia masih relatif terbatas. Oleh karena itu, penelitian ini bertujuan mengembangkan dan membandingkan model Extra Trees Regression dan CART untuk menentukan model paling optimal dalam memprediksi biaya pengiriman e-commerce di Indonesia.

2. Metodologi

2.1 Bahan dan Data

Penelitian ini menggunakan data sekunder yang diperoleh dari dataset Indonesia E-Commerce Sales & Shipping 2023-2025 yang tersedia pada platform Kaggle (Baki Tacos 2025). Dataset ini bersumber dari operasional ritel di e-commerce yang telah dianonimkan sebelum dipublikasikan di Kaggle. Peubah-peubah yang digunakan dalam penelitian ini dapat dilihat pada Tabel 1.

Tabel 1: Daftar Peubah Penelitian.

Kode	Variabel	Satuan	Sumber
Y	perkiraan_ongkos_kirim	Rp (Rupiah)	Kaggle
X1	total_weight_gr	g (Gram)	Kaggle
X2	total_qty	Unit	Kaggle
X3	provinsi	-	Kaggle
X4	opsi_pengiriman	-	Kaggle
X5	product_categories	-	Kaggle
X6	metode_pembayaran	-	Kaggle

Dataset yang digunakan pada penelitian ini terdiri atas 20.848 amatan dan 19 variabel. Dari keseluruhan variabel tersebut, penelitian ini menggunakan 7 variabel yang relevan dengan tujuan pemodelan biaya pengiriman, yang mencakup variabel numerik maupun kategorik.

2.2 Metode Penelitian

Penelitian ini mengimplementasikan pendekatan pemodelan nonlinier berbasis *machine learning* guna memprediksi biaya pengiriman produk *e-commerce* menggunakan metode Extra Trees Regression dan CART. Pemilihan kedua metode

tersebut didasarkan pada kapabilitasnya dalam menangkap keterkaitan nonlinier serta interaksi variabel yang kompleks tanpa bergantung pada asumsi parametrik yang ketat seperti normalitas dan homoskedastisitas (Breiman et al., 1984) menggunakan perangkat lunak R.

1. *Preprocessing Data*

Tahap ini meliputi penghapusan missing value, transformasi variabel kategorik, serta penanganan outlier pada variabel respon menggunakan metode Interquartile Range (IQR) untuk mengurangi pengaruh nilai ekstrem terhadap kestabilan model.

2. *Feature Engineering*

Pada penelitian ini dilakukan feature engineering dengan melakukan transformasi logaritma pada total berat produk (log_weight) guna mengurangi skewness dan pengaruh nilai ekstrem sehingga hubungan antara berat produk dan biaya pengiriman dapat ditangkap secara lebih stabil oleh model. Selain itu, dibentuk variabel baru berupa rasio berat produk terhadap jumlah produk (weight_per_qty) untuk merepresentasikan rata-rata berat per item dalam suatu transaksi.

Secara matematis dirumuskan sebagai berikut:

$$weight\ per\ qty = \frac{total\ weight\ (gr)}{total\ qty}$$

3. *Eksplorasi Data*

Eksplorasi data dilakukan untuk memahami karakteristik data sebelum proses pemodelan meliputi statistik deskriptif, visualisasi histogram, boxplot, dan analisis korelasi antar variabel numerik.

4. *Pembagian data latih dan data uji*

Pembagian data dilakukan secara acak dengan proporsi 80% sebagai data latih dan 20% sebagai data uji. Proporsi ini digunakan agar model memperoleh jumlah data yang cukup untuk mempelajari pola hubungan antar variabel pada tahap pelatihan, sekaligus menyediakan sebagian data yang belum pernah dilihat model untuk mengevaluasi kemampuan prediksi model.

5. *Pengembangan Model Extra Trees Regression*

Extra Trees Regression merupakan metode ensemble yang membangun sejumlah besar pohon keputusan dengan tingkat randomisasi tinggi pada pemilihan fitur dan titik split (Hameed et al., 2021). Prediksi akhir dihitung

sebagai rata-rata seluruh prediksi pohon:

$$\hat{f}(x) = \left(\frac{1}{T}\right) \sum f_t(x)$$

di mana:

- $f_t(x)$ adalah prediksi dari pohon ke- t
- T adalah jumlah pohon dalam ensemble

6. Pengembangan Model Classification and Regression Tree (CART)

Sebagai model pembanding digunakan CART (Breiman et al., 1984), metode nonparametrik berbasis pohon keputusan yang membentuk struktur pohon secara rekursif untuk meminimalkan galat prediksi pada setiap node. Proses pruning dilakukan untuk mengurangi kompleksitas pohon dan menghindari overfitting.

7. Evaluasi dan Penentuan Model Terbaik

Evaluasi performa model dilakukan menggunakan metrik evaluasi untuk memberikan penilaian yang lebih komprehensif terhadap akurasi prediksi, dengan Root Mean Squared Error (RMSE) dan Mean Absolute Percentage Error (MAPE) sebagai indikator utama (Chharia et al., 2024).

a. RMSE

RMSE digunakan untuk mengukur rata-rata besar kesalahan prediksi model terhadap nilai aktual dalam satuan yang sama dengan variabel respon.

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Dengan:

- y_i = nilai aktual
- $\hat{y}_i$ = nilai prediksi
- n = jumlah observasi

Semakin kecil nilai RMSE maka semakin baik performa model.

b. MAPE

MAPE digunakan untuk mengukur rata-rata persentase kesalahan prediksi model terhadap nilai aktual.

$$MAPE = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$


Dengan:

- y_i = nilai aktual
- $\hat{y}_i$ = nilai prediksi
- n = jumlah observasi

Semakin kecil nilai MAPE maka semakin baik tingkat akurasi model dalam memprediksi biaya pengiriman.

3. Hasil dan Pembahasan


3.1 Eksplorasi



Gambar 1: Visualisasi Boxplot Variabel Respon.

Visualisasi melalui boxplot pada Gambar 1 mengidentifikasi keberadaan sejumlah amatan ekstrem yang mengindikasikan distribusi variabel respon bersifat asimetris. Fenomena ini dipertegas oleh *histogram* pada Gambar 2 yang menunjukkan pola *right-skewed* dengan konsentrasi observasi dominan pada rentang Rp 8.000–Rp 11.000, di mana posisi rata-rata berada di sebelah kanan median. Karakteristik tersebut menunjukkan bahwa data respon tidak berdistribusi normal dan mengandung nilai ekstrem, sehingga pendekatan pemodelan berbasis pohon seperti Extra Trees Regression dan CART dipilih karena lebih fleksibel dalam menangani

data dengan distribusi yang tidak normal tanpa bergantung pada asumsi parametrik yang ketat.



Gambar 2: Visualisasi Histogram Variabel Respon.

3.2 Hasil Model Extra Trees Regression

Model Extra Trees dibangun dengan konfigurasi 1.500 pohon keputusan, $mtry = 2$, $min.node.size = 10$, dan $sample.fraction = 0,8$. Model menghasilkan OOB MSE sebesar 22.964.658 dan R^2 OOB sebesar 0,6872 pada data latih. Tabel 2 menyajikan nilai *feature importance* berdasarkan metode permutation importance.

Tabel 2: *Feature Importance* Model Extra Trees Regression (Permutation Importance).

Feature	Importance	Peringkat
Provinsi	58.519.999	1
log_weight	14.397.762	2
weight_per_qty	11.534.364	3
total_weight_gr	11.018.106	4
product_categories	10.391.484	5
Opsi.Pengiriman	9.805.927	6
total_qty	5.174.127	7
Metode.Pembayaran	1.337.254	8

Variabel Provinsi merupakan peubah paling dominan (importance 58.519.999), mengindikasikan bahwa zona geografis adalah determinan utama tarif logistik. Variabel rekayasa fitur log_weight (14.397.762) dan weight_per_qty (11.534.364) menempati peringkat kedua dan ketiga, mengonfirmasi kontribusi informatif fitur hasil rekayasa. Variabel total_weight_gr berada di peringkat keempat dengan nilai yang komplementer terhadap weight_per_qty, sementara kategori produk dan opsi pengiriman mencerminkan pengaruh jenis produk serta pilihan kurir. Metode

pembayaran menunjukkan tingkat terendah, yang mengindikasikan kontribusinya lebih lemah dibandingkan variabel lainnya.

3.3 Hasil Model Classification and Regression Tree (CART)

Model CART dibangun menggunakan 15.229 data latih dengan parameter awal cp 0,001, $minsplit$ 20, dan $maxdepth$ 10. Melalui mekanisme pruning validasi silang, dihasilkan pohon final dengan 41 titik pemisahan serta nilai galat relatif 0,3017 dan $xerror$ 0,3510. Kontribusi variabel, yang dihitung berdasarkan akumulasi reduksi RSS pada setiap titik pemisahan, dipetakan melalui nilai *feature importance* pada Tabel 3.

Tabel 3: *Feature Importance* Model CART Regression (Penurunan RSS).

Feature	Importance (%)	Peringkat
Provinsi	37	1
total_weight_gr	13	2
log_weight	13	3
Opsi.Pengiriman	13	4
weight_per_qty	11	5
product_categories	10	6
total_qty	2	7

Selaras dengan temuan pada model Extra Trees, peubah Provinsi memposisikan diri sebagai determinan paling dominan (importance 37%), yang mengonfirmasi bahwa zonasi geografis merupakan faktor penentu utama dalam pembentukan tarif logistik. Peubah total_weight_gr, log_weight, dan opsi pengiriman masing-masing memberikan kontribusi sebesar 13%, yang merepresentasikan adanya informasi komplementer dalam proses estimasi biaya. Fitur hasil rekayasa weight_per_qty menempati peringkat kelima (11%), sedangkan total_qty mencatatkan kontribusi paling rendah (2%), hal ini mengindikasikan bahwa kuantitas unit tidak memiliki peran sebagai determinan langsung dalam struktur pemodelan CART.

3.4 Evaluasi dan Penentuan Model Terbaik

Tahap evaluasi model diimplementasikan dengan memanfaatkan data uji sebanyak 3.804 amatan dengan enam metrik evaluasi disajikan secara komprehensif pada Tabel 4.

Tabel 4: Perbandingan Metrik Evaluasi Model Extra Trees Regression dan CART.

Metrik	Extra Trees	CART
MSE	27.262.639	26.620.986
RMSE	5.221,364	5.159,553
MAE	3.708,618	3.677,674
MAPE (%)	37,96656	36,06248

R-Squared	0,6290869	0,638549
Korelasi Pearson	0,79315	0,7990926

Berdasarkan hasil komparasi performa, model CART secara konsisten menunjukkan sedikit lebih baik dibandingkan Extra Trees pada seluruh metrik evaluasi, di mana nilai RMSE tercatat sebesar Rp 5.159,55 (vs. Rp 5.221,36), MAE sebesar Rp 3.677,67 (vs. Rp 3.708,62), MAPE sebesar 36,06% (vs. 37,97%), serta koefisien determinasi R-Squared sebesar 0,6385 (vs. 0,6291). Capaian ini mengindikasikan bahwa dominansi variabel Provinsi merepresentasikan struktur data yang mampu ditangkap secara optimal oleh pendekatan pohon keputusan tunggal melalui mekanisme *pruning* yang memadai. Nilai MAPE yang relatif tinggi perlu ditafsirkan dengan hati-hati karena sensitivitasnya terhadap amatan bernilai kecil, sehingga RMSE dan MAE lebih representatif sebagai indikator akurasi utama.

4. Simpulan dan Saran

Penelitian ini memodelkan biaya pengiriman e-commerce di Indonesia menggunakan Extra Trees dan CART Regression berbasis 19.033 data transaksi. Hasil evaluasi menunjukkan CART Regression sebagai model terbaik dengan RMSE Rp 5.159,55, MAPE 36,06%, dan R-Squared 0,6385. Variabel Provinsi menjadi prediktor paling dominan pada kedua model, diikuti faktor berat barang dan opsi pengiriman. Temuan ini mengonfirmasi efektivitas model berbasis pohon dalam menangkap hubungan non linier variabel operasional pengiriman tanpa asumsi parametrik yang ketat.

Keterbatasan studi ini memberikan peluang pengembangan ke depan. Pertama, optimasi hiperparameter belum dilakukan secara sistematis melalui *grid search* atau *random search*, sehingga eksplorasi konfigurasi optimal berpotensi meningkatkan performa model. Kedua, penggunaan jarak pengiriman aktual sebagai prediktor dapat menggantikan variabel Provinsi untuk meningkatkan presisi prediksi secara substantif. Ketiga, perluasan perbandingan dengan metode *ensemble* lain seperti Gradient Boosting atau XGBoost disarankan guna memperoleh gambaran komprehensif mengenai performa berbagai model nonlinier pada logistik e-commerce.

Daftar Pustaka

- Afshar, F., Seyedabrishami, S., & Moridpour, S. (2022). Application of extremely randomised trees for exploring influential factors on variant crash severity data. *Scientific Reports*, 12, 11476. <https://doi.org/10.1038/s41598-022-15693-7>
- Arfeen, M. A. (2024). Machine learning-driven cost prediction in intermodal transport systems. *Journal of Information Systems Engineering and Management*. <https://jisem-journal.com/index.php/journal/article/view/8569>
- Baki Tacos. 2025. Indonesia E-Commerce Sales & Shipping 2023–2025. Kaggle. <https://www.kaggle.com/datasets/bakitacos/indonesia-e-commerce-sales-and-ship>

[ping-20232025](#)

- Bansal, G., & Muzatko, S. (2021). Shipping and return shipping prices and online purchase intentions: The role of gender and product price category. *International Journal of Business*, 26(3), 53–71. <https://ijb.cyut.edu.tw/var/file/10/1010/img/V26N3-4.pdf>
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>
- Cebeci, M. S., de Bok, M., Tapia, R., Nadi, A., & Tavasszy, L. (2025). Feasibility of crowdshipping for outlier parcels in last-mile delivery. *Research in Transportation Economics*, 112, 101607. <https://doi.org/10.1016/j.retrec.2025.101607>
- Chharia, A., et al. (2024). Accuracy of US CDC COVID-19 Forecasting Models. *Frontiers in Public Health*. <https://www.frontiersin.org/journals/public-health/articles/10.3389/fpubh.2024.1359368/full>
- Chowdhury, S., et al. (2021). Evaluation of tree-based regression over multiple linear regression for non-normally distributed data. arXiv preprint arXiv:2111.02513. <https://arxiv.org/abs/2111.02513>
- Geurts, P., Ernst, D., & Wehenkel, L. (2006). Extremely randomized trees. *Machine Learning*, 63(1), 3–42. <https://doi.org/10.1007/s10994-006-6226-1>
- Google, Temasek & Bain & Company. (2025). e-Conomy SEA 2025: ASEAN's digital economy enters the AI reality (10th edition). <https://economysea.withgoogle.com/>
- Hameed, M., et al. (2021). Application of extra trees regression for environmental modeling. *Data in Brief*, 34, 106824. <https://doi.org/10.1016/j.dib.2021.106824>
- Harani, N. H., Setyawan, M. Y. H., & Ferdinan, D. (2025). Predicting basic shipping tariff using machine learning. *Nuansa Informatika*, 19(2), 58–66. <https://journal.fkom.uniku.ac.id/ilkom/article/view/388>
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). The elements of statistical learning: Data mining, inference, and prediction (2nd ed.). *Springer*. <https://hastie.su.domains/ElemStatLearn/>
- Jang, H. S. (2023). Prediction of shipping cost on freight brokerage platform using machine learning. *Sustainability*, 15(2), 1122. <https://doi.org/10.3390/su15021122>
- Zhao, S. (2024). Research on logistics cost prediction based on random forest regression modeling. *Transactions on Economics, Business and Management Research*, 11, 367–376. <https://doi.org/10.62051/mv8p5485>
- Zhang, X., Guo, F., Chen, T., Pan, L., Beliakov, G., & Wu, J. (2023). A Brief Survey of Machine Learning and Deep Learning Techniques for E-Commerce Research. *Journal of Theoretical and Applied Electronic Commerce Research*, 18(4), 2188–2216. <https://doi.org/10.3390/jtaer18040110>
- Zhou, Z.-H. (2021). Ensemble methods: Foundations and algorithms (2nd ed.). CRC Press. <https://tjzhifei.github.io/links/EMFA.pdf>